



Pipeline End-to-End: San Francisco Fire Department

Progetto di Data Engineering che documenta la costruzione completa di una pipeline ETL, dalla fase di ingestione alla containerizzazione finale. Obiettivo: applicare best practice di ingegneria del dato su un dataset reale.

Approccio Iniziale e Analisi Esplorativa

Sfide del Dataset

- Varietà significativa nei tipi di dato
- Volume considerevole di record storici
- Librerie Python da apprendere in corso d'opera
- Definizione da zero di Star Schema

Strategia Adottata

Decisione iniziale di **convertire tutti i campi in stringhe** per comprendere la struttura e i pattern dei dati senza vincoli di tipo. Questo approccio ha permesso un'esplorazione più flessibile del contenuto effettivo.



Ingestione dei Dati e Primo Caricamento

01

Caricamento CSV

Import dei file sorgente nel database relazionale, preservando i dati grezzi così come forniti.

02

Verifica di Integrità

Controllo del numero di record caricati e confronto con i file sorgente per assicurare completezza.

03

Motivazione Layering

Separazione a layer per garantire tracciabilità, permettere riprocessamenti e isolare le trasformazioni.

 **Principio architetturale:** il Bronze layer mantiene i dati immutati per consentire riprocessamenti futuri senza necessità di re-ingestione.

Pulizia e Standardizzazione dei Dati

Selezione Colonne

Identificazione dei campi rilevanti per le analisi previste, scartando metadati ridondanti o non significativi.

Parsing Temporale

Conversione dei timestamp da stringhe a tipi datetime nativi, gestendo formati multipli e inconsistenze.

Standardizzazione Tipi

Applicazione dei tipi di dato corretti (integer, float, date) dopo aver compreso i pattern effettivi.

Gestione Valori Errati

Impostazione a NULL dei timestamp impossibili o fuori range invece di preservare valori invalidi.

Controlli di Qualità sul Silver Layer

- **Query SQL di Validazione**

Verifica di vincoli di integrità, range accettabili e completezza dei campi critici.

- **Blocco della Pipeline**

In caso di fallimento delle verifiche, la pipeline si arresta e genera log dettagliati dell'errore.

- **Stabilità Prima di Proseguire**

Solo con dati validati si procede alla modellazione dimensionale del Gold layer.

Mock-up Dashboard e Validazione del Modello

1

Prototipo Streamlit

Costruzione rapida di una dashboard direttamente sul Silver layer per validare le domande di business.

2

Difficoltà Iniziali

Curva di apprendimento di Streamlit: gestione dello stato, caching, e reattività dei widget.

3

Verifica Rispondibilità

Conferma che i dati disponibili possono rispondere alle query analitiche richieste.

Questo passaggio ha evitato di investire tempo nella modellazione dimensionale di un modello inadeguato.



Modellazione Dimensionale Star Schema



dim_date

Dimensione temporale con granularità giornaliera, attributi per anno, mese, trimestre e giorno della settimana.



dim_incident_type

Classificazione degli incidenti per tipo, sottotipo e categoria, derivata dai codici del sistema di gestione emergenze.



dim_location

Informazioni geografiche: indirizzo, quartiere, coordinate GPS e identificativi dei battalion.



fact_incident

Tabella dei fatti che registra ogni incidente con chiavi esterne alle dimensioni e metriche di risposta.

L'obiettivo è un modello denormalizzato, ottimizzato per query analitiche e aggregazioni rapide.

Problemi Incontrati nel Gold Layer

Join Non Coperte

Alcuni record della fact non trovavano corrispondenza nelle dimensioni, generando righe incomplete.

271 Location ID Nulli

Analisi approfondita ha rivelato indirizzi malformati o mancanti nei dati sorgente.

Raffinamento delle Join

Passaggio da UNION generiche a JOIN più selettive con gestione esplicita dei casi non matchati.

- ❏ La documentazione accurata dei record scartati è fondamentale per la tracciabilità e per future correzioni upstream.



Controlli di Qualità sul Gold Layer



Chiavi Non Nulle

Verifica che tutte le chiavi esterne nella fact table siano popolate correttamente.



Copertura Dimensionale

Controllo che ogni valore di chiave nella fact abbia una corrispondenza nelle dimensioni.



Coerenza Temporale

Validazione che le metriche temporali (durata interventi, tempi di risposta) siano in range plausibile.

Anche qui, il fallimento di un controllo blocca la pipeline per evitare dashboard con metriche errate.

Dashboard e Containerizzazione

Dashboard Finali su Gold

- KPI numeriche aggregate (totale incidenti, tempi medi)
- Serie temporali per trend mensili e annuali
- Grafici di distribuzione per tipo e location
- Filtri dinamici per interattività

Ruolo duplice: strumento di business intelligence e validazione finale della qualità del dato.

Containerizzazione con Podman

- Container limitato al layer di visualizzazione
- Database e tool di sviluppo esclusi

L'immagine risultante è portabile e riproducibile in ambienti diversi.

Dettagli della Containerizzazione con Podman



Ambito Contenuto

La containerizzazione è stata applicata unicamente al layer di visualizzazione, isolando la dashboard Streamlit dal resto dell'infrastruttura.



Esclusioni Architettureali

Il database e gli strumenti di sviluppo sono stati deliberatamente esclusi dal container, mantenendo il focus sulla sola interfaccia utente.



Configurazione Standard

L'implementazione ha fatto uso di `Dockerfile`, `.dockerignore` e variabili d'ambiente per una gestione robusta e riproducibile.

Text-to-SQL: Un Tentativo e le Sue Sfide



Integrazione Chatbot

Abbiamo esplorato l'integrazione di un chatbot text-to-SQL per consentire interrogazioni al database in linguaggio naturale.



Uso di Gemini API

Il prototipo ha fatto leva sull'API di Gemini per le sue avanzate capacità di comprensione del linguaggio naturale e generazione di query SQL.



Ostacoli: Quota e Billing

Il progetto ha incontrato difficoltà significative legate alle restrizioni di quota e alle complessità di billing della Gemini API.



Funzionalità Comprometssa

Nonostante la validità concettuale, l'operatività della feature è stata seriamente limitata dalla difficoltà di accesso all'API.



Considerazioni Future

Sono in corso valutazioni per migliorare l'accesso o esplorare alternative che possano supportare pienamente questa importante funzionalità.

