




Fase 2 — Data Engineering Pipeline

Trasformazione incrementale, idempotente e orchestrata

Obiettivo della Fase 2

Introduzione all'obiettivo principale del progetto



Sistema Incrementale

Trasformare la pipeline in un sistema **incrementale e idempotente**.

Data Lake

Basato su Data Lake in formato **Parquet** per efficienza.

Schedulabile e Orchestrata

Pipeline è **schedulabile** e pronta per pubblicazione applicativa.

Pubblicazione Applicativa

Garantisce una **pubblicazione efficace** di applicativi basati su dati.

Generazione Dati Sintetici



Modello Random Forest

Addestramento su dati Silver con 200k record.



Dataset Calls

Generazione di un dataset sintetico per analisi.



Dataset Incidenti

Derivato via codice per garantire coerenza.

Nuova Pipeline e Data Lake

01

Data Lake
Parquet

Utilizza filesystem
per archiviazione
efficiente.

02

Ingestione
Incrementale

Processa file CSV in
modo continuo.

03

Separazione
Layer

Bronze, Silver e
Gold categorizzati
chiaramente.


Garanzia di Idempotenza

Identificazione file

L'identificazione dei file avviene tramite **hash SHA256**, assicurando un metodo robusto per il tracciamento e la gestione dei dati nel sistema.

Evitare rielaborazioni

Questo meccanismo previene la **rielaborazione dei dati già presenti**, garantendo che solo i nuovi contenuti vengano processati e aumentano l'efficienza del pipeline.



Gestione delle Criticità

Affrontare le sfide del progetto



Incompatibilità naming

Risoluzione delle discrepanze tra DuckDB e Parquet.

Standardizzazione nomi

Implementazione di convenzioni lower_snake_case per coerenza.

Refactor funzioni

Adattamento delle funzioni della Fase 1 per il nuovo storage.

Stabilizzazione layer

Assicurare la stabilità dei layer Bronze e Silver.

Orchestrazione Pipeline

Automazione e gestione delle risorse



Uso di Prefect

Prefect gestisce l'orchestrazione locale della pipeline.

Pipeline Giornaliera

Ogni giorno, la pipeline si attiva automaticamente.

Worker Dedicato

Un worker Prefect è dedicato al processo di esecuzione.

Skip Automatico

Skip automatico per Silver e Gold senza nuovi dati.

Pubblicazione Applicativa

01

Database di
serving

Creazione di un
database separato

02

Esportazione
KPI

Solo KPI aggregati
e dimensioni
leggere

03

Versione “lite”

Serving DB come
versione
semplificata

Risultato Finale

Sintesi delle caratteristiche del progetto
completato



Pipeline end-to-end

Una soluzione integrata per gestire i dati.

Incrementale e idempotente

Processi dati senza duplicazioni o errori.

Orchestrata e cloud-ready

Facilita l'integrazione con servizi cloud.

Estendibile a containerizzazione

Supporto per implementazione tramite Podman o Docker.